

Introduction

Ce document permet d'aider un gestionnaire de Système d'Information (SI) à décrire son domaine dans un fichier de configuration. Lorsque l'on dépose ce fichier dans l'application, cela crée une base de données et les outils permettant de l'alimenter et de la consulter.

Chaque fichier de configuration déposé générera un schéma dédié dans la base de données.

Préalable

Avant de commencer l'écriture du fichier de configuration, il faut travailler à définir le modèle des données que vous voulez traiter dans la base de données.

Vous avez en votre possession un certain nombre de fichiers (format csv) contenant les données. Un fichier de données respecte un certain format. En particulier les en-têtes de colonnes doivent être fixés et le contenu sous un en-tête a un format déterminé (date, valeur flottante, entier, texte..).

Chaque format de fichier correspond à ce que l'on appellera un type de données. Il regroupe plusieurs variables correspondant à : - une thématique, - un pas de temps, - une structuration des données - ...

Chaque ligne peut être identifiée par sous-ensemble de colonnes. Cet identifiant permet de créer ou de mettre à jour une donnée, selon qu'elle est ou non déjà présente en base.

Chaque ligne porte, sur une ou plusieurs colonnes, une information de temporalité.

Chaque ligne porte aussi, sur une ou plusieurs colonnes, des informations sur le contexte d'acquisition des variables des autres colonnes.

On peut vouloir aussi faire figurer dans la base de données certaines informations non présentes dans le fichier de données.

- des informations liées aux variables que l'on fournit sous la forme de fichier de référentiels (description de site, description de méthodes, description d'unités, description d'outils...)
- des informations constantes, ne dépendant pas du fichier (par exemple l'unité de la variable)
- des informations constantes pour l'ensemble du fichier (par exemple le site correspondant aux valeurs du fichier). Ces informations pouvant être décrites dans un cartouche, avant l'en-tête de colonne ou juste sous l'en-tête de colonne (valeur minimum ou maximum)
- des informations calculées à partir d'informations du fichier, d'informations des référentiels déjà déposés ou même des données déjà publiées.

exemple

Supposons que l'on ait un fichier de données météorologiques

```
Région;Val de Loire;;;
Période;06/2004;;;
Date de mesure;Site;Précipitation;Température moyenne;Température minimale;Température maximale;
01/06/2004;0s1;30;20;10;24
07/06/2004;0s1;2;22;14;27
07/06/2004;0s2;0;21;9;28
```

- La temporalité est portée par la colonne “Date de mesure”.
- Le contexte est porté par l’information du cartouche d’en-tête “Région” et la colonne “Site”.
- On identifie 4 variables:
- *date* au format dd/MM/yyyy (format au sens SQL : <https://www.postgresql.org/docs/current/functions-formatting.html#FUNCTIONS-FORMATTING-DATETIME-TABLE>). Cette variable n’a qu’une seule composante “day”. On note que les moyennes sont calculées à la journée.
- *localization* qui fait référence à un site de la colonne “Site”, avec deux composantes (site et region)
- *precipitation* qui correspond à la pluviométrie de la colonne “Précipitation” avec deux composantes (value,unit=mm)
- *temperature* qui se réfère aux colonnes “Température moyenne”, “Température minimale” et “Température maximale” avec 4 composantes (value,min,max,unit=°C)

Du coup, on peut aussi définir des référentiels pour préciser ses informations

region.csv

```
code ISO 3166-2;nom
FR-ARA Auvergne-Rhône-Alpes
FR-BFC Bourgogne-Franche-Comté
FR-BRE Bretagne
FR-CVL Centre-Val de Loire
FR-COR Corse
FR-GES Grand Est
FR-HDF Hauts-de-France
FR-IDF Île-de-France
FR-NOR Normandie
FR-NAQ Nouvelle-Aquitaine
FR-OCC Occitanie
FR-PDL Pays de la Loire
FR-PAC Provence-Alpes-Côte d'Azur
```

site.csv

```
nom:Date de création;region  
0s1;01/01/2000;FR-CVL  
0s2;01/01/2000;FR-CVL
```

Les sites font référence aux régions.

unite.csv

```
nom;nom_fr;nom_en;code  
temperature;Température;Temperature;°C  
precipitation;Précipitation;Precipitation;mm
```

Le fait de dire que l'unité d'une donnée fait référence au référentiel unite signifie : - que l'unité doit être présente dans ce référentiel, - que l'on ne pourra pas supprimer une unité du référentiel si on y a fait référence.

On aurait pu rajouter des responsables de site et de région, des descriptions des variables, des intervalles de valeurs...

Ainsi nous avons pu faire une analyse de notre domaine et le format des fichiers qui s'y rapportent. Nous pouvons commencer l'écriture du fichier de configuration.

Vocabulaire

Clefs et code

Dans un fichier, on définit une ou plusieurs colonnes qui correspondent à la clef d'identification de la ligne. Cette clef naturelle permet lors d'une insertion / suppression de retrouver cette ligne dans la base de données et, si elle est présente, de la mettre à jour. Dans le cas contraire, une nouvelle ligne est créée.

code

Pour enregistrer ces clefs dans la base de données, et pour éviter les erreurs, les clefs sont codées. Le code utilisé n'autorise que les chiffres, les lettres minuscules et majuscules ainsi que le caractère souligné (underscore).

Cependant, pour permettre une plus grande souplesse, les accents sont supprimés, les majuscules sont remplacées par les minuscules, les espace et les tirets (-) sont remplacés par des _ et les autres caractères sont remplacés par leur nom ascii en majuscules.

- L'année de départ -> LAPOSTROPHEannee_de_depart

- $\mu\text{mol m}^{-2} \text{ s}^{-1}$ -> MICROSIGNmol_m2_s1
- m^2/m^2 -> mSUPERSCRIPTTWOSOLIDUSmSUPERSCRIPTTWO
- $^{\circ}\text{C}$ -> DEGREESIGNc

Ainsi les valeurs Elévation, élévation, elevation ou même EléVaTioN renvoient toutes le même code.

Ces transformations sont faites de manière transparente.

:information_source : Quand on fait référence à un référentiel, que cela soit pour un type de données ou pour un autre référentiel, on utilise la clef naturelle de ce référentiel. Cependant, il sera possible de demander la mise en code de la valeur avant de rechercher son existence dans le référentiel de référence.

Clef naturelle.

Elle est construite en concaténant les valeurs des différentes colonnes composant la clef. Le signe de concaténation est le double underscore '___'.

- Forme géométrique de la colonie + prisme -> forme_geometrique_de_la_colonie___prisme
- Ensoleillement + Ensoleillé -> ensoleillement___ensoleille
- Piégeage en montée + Couleur des individus -> piegeage_en_montee___couleur_des_individus

Clef hiérarchique

Elle est construite en concaténant les clefs naturelles de différents référentiels. Le signe de concaténation de la clef hiérarchique est le point '.'.

Ainsi si on a une parcelle "1", dans le site "Site 1" du type de site "Site d'étude" :

réfèrentiel	Clef naturelle	Clef hiérarchique
Type Site étude de site	site_etude	siteKsite_etude
Site Site 1	site_etude___site_1	siteKsite_etude.site_etude___site_1
Parcelle	site_etude___site_1___1	parcelleKsite_etude.siteKsite_etude___site_1.1

Référentiels

references: Un ensemble d'informations permettant de préciser le contexte de la mesure ou de l'observation.

En déportant ces informations dans des fichiers **references**, on évite la répétition d'informations. On utilisera la clef d'une information pour y faire référence.

Types de données

data : un ensemble de données correspondant à une thématique et un format de fichier commun.

variable : correspond à un ensemble de données, qualifiant ou se rapportant à une variable de mesure, d'observation, d'informations, de temporalité ou de contexte.

component : un ensemble de valeur qui servent à décrire une variable (valeur, écart type, nombre de mesures; indice de qualité; méthode d'obtention...)

authorizationScope : une ou des informations contextuelles (variable-component) qui ont du sens pour limiter les autorisations.

timeScope : l'information de temporalité d'une ligne ayant du sens pour limiter des autorisations à une période.

Aide fichier à la rédaction du fichier de configuration

La création :

Vous trouverez ci-dessous un exemple de fichier Yaml fictif qui décrit les parties attendues dans celui-ci pour qu'il soit valide. **Attention le format Yaml est sensible** il faut donc respecter l'indentation.

Il y a 5 parties (sans indentation) attendues dans le fichier :

- version,
- application,
- references,
- compositeReferences,
- dataTypes

l'indentation du fichier yaml est très importante.

Description du fichier

Informations sur le fichier lui-même

Version de l'analyseur (parser) du fichier de configuration.

Soit version actuelle du site qui est 1 actuellement. Il faut avoir en tête que lorsque l'application évolue et que la version de l'analyseur s'incrémente, le fichier de configuration peut ne plus être valide.

```
version: 2.0.1
```

version n'est pas indenté.

On présente l'application avec son nom et la version du fichier de configuration :

(on commence par la version 1)

S'il y a déjà une application du même nom, mais que l'on a fait des modifications dans le fichier, on incrémente la version.

```
OA_application:
  OA_name: application_minimale
  OA_i18n: # optional
    OA_title:
      fr: Configuration minimale
      en: Minimale configuration
    OA_description:
      fr: Fichier de configuration minimum
      en: Minimum configuration file
  OA_version: 1.0.1
  OA_defaultLanguage: en # optional par défaut fr
  OA_comment: une application pour rien faire # optional
```



Les sections d'internationalisation ne sont pas obligatoires, mais permettent une internationalisation des interfaces.

application n'est pas indenté. *name*, *internationalizationName* et *version* sont indentés de 1.



Vous trouverez le formalisme d'un fichier yaml sur cette [page](#).

Certains éditeurs de texte permettent d'écrire un yaml avec colorisation et mise en relief des erreurs. Par exemple l'éditeur de texte ou kate (linux) ou bien Notepad++ (windows)